File chung cho Ka và Ko

Đọc file này trước, khoảng 1 giờ. Sau đó Ka đọc file `01`, Ko đọc file `02`, khoảng 2 giờ mỗi bạn.

1. Bảng phân công lý tưởng

Đây là cách chia việc lý tưởng cho dự án, **không phải nhật ký** những việc đã diễn ra.

Hạng mục	Phụ trách	Sản phẩm	Xong khi
Kiểm tra dữ liệu, nhãn, chia tập	Ka	`data_audit.json`, `eda_by_level.csv`	Giải thích được một dòng thật và một rủi ro dữ liệu
Baseline majority, cây AWL	Ka	`awl_tree_rules.txt`, `frozen_selection.json`	Tự dò cây bằng tay trên một câu
Ca bất đồng nhãn, ca cây AWL sai	Ka	Phần 4, 5 của file `03`	Đọc và nói được bằng chứng từng ca
Chạy lại và kiểm chứng kết quả	Ka	`verification.json`	Chạy verify và đọc được kết quả
TF-IDF + LR	Ko	`tfidf_lr.joblib`, `lr_top_coefficients.csv`	Lần theo được một câu ra dự đoán
Thước đo và so sánh	Ko	`test_metrics.csv`, `per_class_test.csv`	Tính tay được một thước đo nhỏ
Controlled check	Ko	`output/experiments/dev-checks/`	Nói được giả định, kết quả, quyết định
Ca lỗi của LR	Ko	Phần 3 của file `03`	Đọc và nói được bằng chứng từng ca
Kết luận và giới hạn	Cả hai	Mục kết luận của báo cáo	Mỗi người tự nói được một giới hạn

Bảng ca lỗi và controlled check do AI soạn. Nếu thầy hỏi ai làm, hãy trả lời đúng như vậy.

2. Buổi phỏng vấn kiểm tra gì

Mỗi người khoảng 6–8 phút, điểm riêng, tối đa 30.

Tiêu chí	Điểm	Thầy muốn thấy
Dữ liệu và nhãn	8	Mở một câu có ID. Một dòng là gì, nhãn từ đâu, lúc dự đoán biết gì, chia tập ra sao, một rủi ro
Lý do chọn mô hình	8	Từ đặc trưng đến dự đoán. Baseline để làm gì. Nếu đổi điều kiện thì sao
Đánh giá và kết quả	8	So với baseline, đọc một thước đo, một ca lỗi, một giới hạn, tập test đã dùng thế nào
Đóng góp và kiểm tra thực hành	6	Làm hoặc dò một bước nhỏ, tính một thước đo nhỏ, đoán đầu vào đổi thì sao

Quy định cần nhớ:

- Được mở tài liệu và code của mình. **Bạn bè và AI không được nhắc** khi đang phỏng vấn.
- Được trả lời bằng tiếng Việt, được viết hoặc vẽ.
- Thầy sẽ đổi ví dụ, nên học thuộc không đủ. Hãy hiểu **cách dò**.
- "Em chưa đủ bằng chứng để khẳng định, nhưng có thể kiểm tra bằng cách..." là câu trả lời được tính.
- Không cần huấn luyện lại trên lớp. Thầy có thể dùng kết quả đã lưu.

Mỗi tiêu chí chấm 0, 4, 6 hoặc 8 (tiêu chí cuối: 0, 3, 4,5 hoặc 6). Chỉ đọc thuật ngữ thì được khoảng mức 4. Giải thích đúng một câu thật được mức 6. Nối được các bước và suy luận khi điều kiện đổi được mức 8.

3. Dự án trong một trang

Câu chuyện: cô giáo tiếng Anh ở HANU có một bài đọc cho lớp B1. Cô muốn biết câu nào có thể khó hơn trình độ lớp để sửa hoặc thay.

Công cụ làm gì: đọc **một câu tiếng Anh**, đoán câu đó thuộc mức nào trong sáu mức.

```
A1 → A2 → B1 → B2 → C1 → C2
dễ nhất                khó nhất
```

- **Đầu vào:** chỉ chữ của một câu.
- **Đầu ra:** một nhãn và 6 xác suất.
- **Người quyết định:** giáo viên. Công cụ chỉ gợi ý.
- **Không làm:** không chấm cả bài đọc, không tự viết lại câu.

Tiến độ thật:

Đã có	Chưa có
Kiểm tra dữ liệu, 3 mô hình, kết quả test	Báo cáo cuối
Chạy lại và kiểm chứng tự động	Khoảng tin cậy cho hiệu số giữa hai mô hình
Controlled check và bảng ca lỗi (AI soạn)	BiLSTM, giao diện cho giáo viên, thử với giáo viên thật

4. Machine Learning là gì

Lập trình thường: bạn viết luật cho máy. Ví dụ: "điểm dưới 4 thì trượt môn."

Machine Learning: bạn đưa ví dụ có đáp án, máy tự tìm luật. Giống như xem 100 câu đã có đáp án rồi tự rút kinh nghiệm cách làm bài.

Bốn từ phải nhớ:

Từ	Nghĩa	Trong dự án
Mẫu (sample)	Một ví dụ	Một câu tiếng Anh
Nhãn (label)	Đáp án	A1 đến C2, do chuyên gia gán
Đặc trưng (feature)	Con số mô tả mẫu, vì máy chỉ làm việc được với số	Mật độ từ học thuật, trọng số của từng từ

Từ	Nghĩa	Trong dự án
Mô hình (model)	Luật máy học được	Cây quyết định, Logistic Regression

Ba tập dữ liệu giống ba loại đề

Tập	Số câu	Giống như	Dùng để
Train	7.177	Đề cương có đáp án	Máy học
Dev	1.366	Đề thi thử	Chọn cấu hình tốt nhất
Test	1.460	Đề thi thật	Chấm cuối cùng

Vì sao không gộp lại? Nếu thi đúng câu đã có trong đề cương, điểm cao chưa chắc đã giỏi. Có thể chỉ là học thuộc. Hiện tượng này gọi là **overfitting** (học thuộc đề cũ, gặp đề mới thì dở). Nếu đề thi lọt vào lúc ôn thì gọi là **rò rỉ** (leakage).

Tập test đã dùng thế nào: nhóm chọn xong và đóng băng mô hình bằng dev, rồi mới chấm test. Code từ chối chạy test lần hai trong cùng thư mục. Chạy lại ở thư mục khác cũng không làm test thành "chưa từng thấy", và không được chỉnh mô hình dựa trên điểm test.

Baseline là gì

Baseline là mốc so sánh đơn giản. Một bài trắc nghiệm mà khoanh bừa toàn C đã được 25%. Nếu bạn ôn cả tuần mà được 26%, bạn chưa giỏi lên bao nhiêu. Vì vậy điểm của mô hình chỉ có nghĩa khi so với mốc.

5. Ba mô hình trên một câu thật

Câu mẫu: `score_dev_0045`: `Here is the area where the computer was .`, nhãn đúng **A2**. Câu này thuộc tập dev, mô hình chưa học nó.

Mô hình	Cách nghĩ	Đoán	Đúng?
Majority	Khoanh toàn một đáp án phổ biến nhất trong train	B2	Sai
Cây AWL	Đếm từ học thuật: `area`, `computer` là 2/8 = 0,25	C1	Sai
TF-IDF + LR	Cộng trừ điểm cho từng từ	A2 (66,3%)	Đúng

Chuỗi xử lý (pipeline):

```
Câu → tách từ → đặc trưng → mô hình → 6 xác suất → nhãn → so với đáp án
```

Thử ngay: mở `2_du_doan_mot_cau.bat`, gõ câu trên, xem có ra đúng bảng này không.

6. Kết quả chính

Cả ba mô hình chấm trên cùng 1.460 câu test.

Mô hình	QWK (cao tốt)	MAE (thấp tốt)	Macro-F1 (cao tốt)	Accuracy
Luôn đoán B2	0,000	0,894	0,080	31,4%
Cây AWL	0,246	1,811	0,078	10,3%

Mô hình	QWK (cao tốt)	MAE (thấp tốt)	Macro-F1 (cao tốt)	Accuracy
TF-IDF + LR	**0,547**	**0,728**	**0,266**	**40,2%**

- **QWK:** mức đồng thuận với chuyên gia, lệch càng xa phạt càng nặng. Bằng 0 là không hơn đoán theo may rủi, gần 1 là rất khớp.
- **MAE:** trung bình lệch bao nhiêu bậc. 0,728 là lệch chưa đến một bậc.

Được phép nói:

- Trên cùng tập test, LR tốt hơn hai mô hình còn lại theo QWK và MAE.
- LR vẫn yếu: không đoán đúng câu A1 hay C2 nào trên test.
- Mô hình mới được đánh giá ở mức câu.

Không được nói:

- "Mô hình đã dùng được trong lớp học." Chưa thử với giáo viên thật.
- "AWL vô dụng." Chỉ kết luận được về cách cài đặt này.
- "Xác suất 66% nghĩa là chắc chắn 66%." Xác suất chưa được hiệu chỉnh.
- So trực tiếp với điểm của bài báo gốc. Cách lấy nhãn khác nhau.

7. Tự kiểm tra

1. Một dòng dữ liệu là gì? Mô hình được thấy gì lúc dự đoán?
2. Vì sao cần cả dev lẫn test?
3. Với câu bất kỳ, baseline đoán gì? Vì sao?
4. Tại sao accuracy của LR chỉ 40% mà MAE dưới 1?

8. Dùng AI thế nào cho đúng

AI giống một bạn học giỏi nhưng đôi lúc nói sai rất tự tin. Được nhờ giải thích, nhưng không được chép đáp án rồi coi là của mình.

Nên	Không nên
Nhờ giải thích khái niệm, rồi tự giải thích lại bằng một câu thật	Nộp phần giải thích của AI như thể tự làm
Nhờ tìm lỗi code, rồi chạy lại để xác nhận	Tin con số AI nói mà không đối chiếu file kết quả
Ghi rõ đã dùng công cụ gì, vào việc gì, kiểm tra thế nào	Dùng AI để nhắc khi đang phỏng vấn

Công khai AI trong dự án này: Claude (AI) đã soạn bảng ca lỗi, controlled check và các file học. Cách kiểm tra: chạy lại code, tính lại số liệu từ file kết quả đã lưu. Phần giải thích ca lỗi là suy luận, chưa phải nguyên nhân đã chứng minh.

9. Từ điển nhanh

Thuật ngữ	Nghĩa
CEFR	Thang trình độ ngoại ngữ A1–C2
SCoRE, Wiki-Auto	Hai nguồn câu: câu ví dụ cho người học, và câu Wikipedia
AWL	Academic Word List, danh sách từ học thuật. Không phải thang CEFR

Thuật ngữ	Nghĩa
Siêu tham số	Núm chỉnh do người chọn, ví dụ số lá của cây
Đóng băng	Chốt mô hình lại trước khi chấm test
Seed	Số cố định để phần ngẫu nhiên lặp lại y hệt
Ma trận nhầm lẫn	Bảng cho biết đáp án thật nào bị đoán thành mức nào
Controlled check	Đổi đúng một yếu tố để kiểm tra một giả thuyết
Bootstrap	Rút lại mẫu nhiều lần để xem con số dao động bao nhiêu

10. Mang theo khi phỏng vấn

- Laptop đã giải nén gói code, đã bấm thử cả 3 file `.bat`.
- File `00`, file của mình, file `03`.
- Giấy bút để tính tay và vẽ.
- **Nếu máy hỏng:** báo thầy ngay, dùng PDF này và tính trên giấy. Rubric cho phép dùng kết quả đã lưu hoặc kiểm tra tương đương.

Đáp án tự kiểm tra

1. Một câu tiếng Anh. Lúc dự đoán chỉ thấy chữ của câu, không thấy nhãn của chuyên gia.
2. Dev dùng để chọn cấu hình. Sau khi chọn, dev không còn khách quan nữa, nên cần test chưa dùng để chấm cuối.
3. Luôn là B2, vì B2 phổ biến nhất trong train (2.472/7.177 câu).
4. Đoán trúng chính xác chỉ 40%, nhưng đa số câu sai chỉ lệch một bậc nên trung bình lệch dưới 1.